

Examen Aprendizaje Automático y Minería de Datos

Grado en Desarrollo de videojuegos, enero 2026

Instrucciones generales

El examen consta de dos partes, una teórica que vale 2 puntos y una práctica que vale 8 puntos.

La parte teórica se entregará en el campus con el nombre del alumno sin espacios y en pdf (Podéis usar word para exportar a PDF Archivo>exportar>crear pdf), word o txt.

La parte práctica se debe entregar en un Jupiter Notebook dentro de un zip o en su defecto en un fichero .py de Python normal.

En el zip también debéis incluir vuestra librería con la implementación del perceptrón multicapa generalizado para múltiples capas y neuronas por capa. Esta librería se debe basar en el código entregado en la práctica 4 y 5 aunque puede tener modificaciones.

Si el código no tiene nada que ver con el de la práctica 5 se considerará copia del examen y se suspenderá la asignatura.

La práctica debe ser ejecutable sin intervención del profesor, si no ejecuta habrá penalización en la nota.

Se permite para la realización de la parte práctica y teórica el uso de los recursos del campus, apuntes y cualquier material de apoyo que traigáis. No tendréis acceso a internet, sólo al campus para todo el examen.

No está permitido el uso de ChatGPT o herramientas de IA similares ni establecer comunicación entre vosotros o con terceros. Si se detecta, la práctica se considerará copiada y tendrá un 0. Tampoco está permitido el móvil durante la realización del examen.

Parte teórica (2 puntos)

Pregunta 1 (0.25 puntos)

Dado el siguiente escenario: Tenemos un modelo que tiene un accuracy de entrenamiento de 90, un accuracy de validación de 80 y un accuracy de test (sin intervención en el entrenamiento) de 70. Describeme razonadamente que te indican estos datos sobre el modelo, los datos y su entrenamiento.

Pregunta 2 (0.25 puntos)

Si tenemos un accuracy de 90 en entrenamiento y un accuracy de 70 en validación en un modelo que acabamos de entrenar. ¿Qué acciones harías para mejorar los resultados? Razona la respuesta.

Pregunta 3 (0.25 puntos)

Si en un entrenamiento, dependiendo del random state, el accuracy de validación cambian entre valores comprendidos entre 0.7 y 0.9. ¿Qué puede estar pasando y cómo lo solucionarías?

Pregunta 4 (0.25 puntos)

Si disponemos de estas matrices de confusión donde las filas son los valores predichos y las columnas los valores reales de dos modelos entrenados con el mismo dataset. ¿Qué podemos decir de ambos modelos? ¿En qué escenarios sería preferible un modelo sobre otro? Razona la respuesta.

A	T	F
T	100	2
F	20	88

B	T	F
T	115	10
F	5	80

Pregunta 5 (0.25 puntos)

Hemos entrenado un modelo de perceptrón multicapa con un dataset de datos proporcionado con 10 parámetros de entrada. Después de probar todos los hiperparámetros posibles del modelo, no conseguimos que el error de validación supere el base line de performance requerido del 80% obteniendo un 77% de máximo, aunque el de entrenamiento si que consigue superar ese 80% obteniendo un 87%. Ante esta situación, explica qué medidas deberías tomar para poder conseguir un modelo que supere potencialmente ese 80%.

Pregunta 6 (0.25 puntos)

Disponemos de un conjunto de imágenes que queremos clasificar y para ello utilizamos un modelo convolucional compuesto por capas convolucionales y full connect, pero tras varios intentos de que aprenda correctamente, nuestro accuracy de validación no llega al requerido y hemos detectado que el accuracy de entrenamiento y el de validación les separa un 20% a favor de el de entrenamiento. ¿Qué podríamos hacer para mejorar el resultado?

Pregunta 7 (0.25 puntos)

Qué tipo de red utilizarías para a partir de un dataset de imágenes de números escritos a mano como el de la práctica 4, y el dígito de la red introducida por teclado por el usuario, la red sea capaz de generar imagen de dicho número. Explica brevemente cómo lo entrenarías.

Pregunta 8 (0.25 puntos)

Necesitamos construir un modelo que nos permita construir un agente que sea capaz de superar un juego de tipo rogue en el que los escenarios son generados proceduralmente. El agente debe poder superar el juego, pero no importa el tiempo que tarde en aprender a hacerlo ¿Qué tipo de modelo utilizarías? Razona la respuesta.

Tiempo estimado 40 minutos, tiempo máximo 50 minutos.

Parte práctica (8 puntos)

Tiempo estimado 1:50 h, tiempo máximo 2:20 h.

Disponemos del dataset **Customer.csv** que se adjunta junto con el enunciado del examen. Dicho dataset contiene información acerca de perfiles de clientes:

Variable Definition * ID: identificador único. * Gender: género. * Ever_Married: casado o soltero * Age: edad * Graduated: Está graduado o no. * Profession: Profesión. * Work_Experience: años de experiencia laboral * Spending_Score: Puntuación de gasto del cliente

* Family_Size: Número de miembros de la familia del cliente (incluido el cliente)
* Var_1: Categoría anónima para el cliente * Segmentation (target) Segmento de consumidor al que pertenece.

Se desea construir varios modelos para estudiar el comportamiento de los mismos para predecir ante un nuevo cliente, a qué segmento pertenece.

Ejercicio 1 (1 punto) Limpia el dataset y realiza las transformaciones necesarias para que los datos puedan ser aplicables a cualquier modelo de machine learning. Justifica en una celda de markdown las decisiones que has tomado. Aplica algún tipo de imputación a al menos un atributo. Elige cuál tendría más sentido y justifícalo en markdown.

Ejercicio 2 (0.5 puntos): Representa gráficamente los datos para mostrar la distribución de las clases con un gráfico de dispersión donde cada clase tenga un color.

Ejercicio 3 (2 puntos): Usa vuestro Perceptrón Multicapa de la práctica 4 y 5 para construir el modelo de predicción. Calcula accuracy y la matriz de confusión. Realiza una partición con **random_state=13** y tamaño del test 20% El resultado mínimo que debéis conseguir de precisión es de un 50%.

El modelo puede tener cualquier capa, pero **debe existir una prueba realizada con al menos tres capas ocultas**, aunque no sea el modelo definitivo que establezcáis porque no produzca el mejor resultado. **Dejad bien claro cual es el modelo con el que finalmente os quedais**, en caso de que haya dos versiones.

Ejercicio 4 (1 punto): Usa MLPClassifier de SKLearn para entrenar un modelo. Dicho modelo debe conseguir al menos un 50% de accuracy. La

configuración puede ser diferente de la del ejercicio anterior

Ejercicio 5 (1 puntos): Usa el algoritmo KNN para conseguir una precisión del 48%.

Ejercicio 5 (1 puntos): Usa el algoritmo RandomForestClassifier para conseguir una precisión del 53%.

Ejercicio 5 (0.5 puntos): Analiza el accuracy de entrenamiento y validación e explica la situación que detectes en base a los resultados de tu modelo y si fuese necesario, que medidas podrías tomar para mejorar los resultados.

Ejercicio 6 (1 puntos): implementa la opción de que las capas ocultas pueda utilizar como función de activación tanto relu como sigmoidal y la capa de salida tanto sigmoidal como softmax. Para ello hay que modificar una copia de vuestro perceptrón multicapa que se llamara MLPRelu en la que en el constructor debe aparecer los siguientes campos:

```
"""
Constructor: Computes MLPRelu.
Args:
    inputLayer (int): size of input
    hiddenLayer (int): size of hidden layer.
    outputLayer (int): size of output layer
    seed (scalar): seed of the random numeric.
    epislom (scalar) : random initialization range. e.j: 1 = [-1..1], 2 = [-2,2]...
    function = "sigmoid" | "relu"
    out_function = "sigmoid" | "softmax"
"""
```

```
def __init__(self, inputLayer, hiddenLayer, outputLayer, seed=0, epislom = 0.12, function = "s
```

Para probar que funciona, entrena un modelo con Relu y softmax que de un valor similar al obtenido con sigmoidal.

La derivada de relu es la siguiente:

$(a > 0) * 1$

Cuando useis Relu, el cross entropy (cost) debe calcularse con la función xlogy de scipy.special para evitar que se generen valores $\text{Log}(0)$ que generan valores NaN.